

Erkennung von Schreibaktivität anhand inertialer Sensordaten einer Smartwatch

Noah Samel (4004067)
noah.samel@stud.leuphana.de

Tajuddin Snasni (TODO: Matrikelnummer)
tajuddin.snasni@stud.leuphana.de

2. September 2026

Zusammenfassung

Handschriftliches Schreiben ist eine alltägliche Tätigkeit, die bislang meist mit instrumentierten Stiften oder Kameras erfasst wird. Diese Arbeit untersucht, ob sich Schreibaktivität allein aus den Daten der inertialen Messeinheit (IMU) einer Smartwatch am Schreibhandgelenk erkennen lässt, unabhängig von der tragenden Person. Dafür wurde ein eigenes Erfassungssystem aus Apple Watch, iPhone-Bridge und Server entwickelt; ein Moleskine Smart Pen lieferte die Ground Truth, deren Strichereignisse über eine varianzbasierte Zeitausrichtung mit den Watch-Daten verknüpft werden. Unter einem Latin-Square-balancierten Studienprotokoll mit Schreibaufgaben und gezielt schreibähnlichen Gegenaufgaben (Tippen, Scrollen, Gestikulieren) entstand ein Datensatz mit 32 Personen und rund 11,5 Stunden annotierter Daten. Alle Modelle wurden mit einer gruppierten fünffachen Kreuzvalidierung über die Personen bewertet, sodass keine Person je in ihrem eigenen Training war. Ein Random Forest auf 88 Merkmalen je Sekunde erreicht 0,865 Genauigkeit und 0,942 ROC-AUC und mit einem nachgeschalteten Zwei-Zustands-HMM 0,898. Den höchsten beobachteten Mittelwert erreicht ein zeitliches Faltungsnetz mit rekurrentem Kopf auf 5-s-Fenstern mit 0,921 Genauigkeit und 0,975 ROC-AUC; für die Netze liegen auf dieser Kohorte keine personenweisen Vorhersagen vor, ihr Vorsprung ist deshalb nicht gepaart getestet. Wir schließen, dass ein personenunabhängiger Schreibdetektor auf einer Smartwatch möglich ist und dass weitere Fortschritte eher von vielfältigeren Trainingspersonen als von neuen Modellen zu erwarten sind.

***Schlagwörter:** Aktivitätserkennung; Inertialsensorik; Wearable Computing; Schreiberkennung; maschinelles Lernen.*

1 Einleitung

2 Verwandte Arbeiten

3 Datenerhebung

3.1 Erfassungssystem

Die zentrale Herausforderung beim Aufbau des Datensatzes bestand darin, ein präzises Referenzsignal (Ground Truth) für den ansonsten nicht direkt beobachtbaren Übergang zwischen Schreiben und Nicht-Schreiben zu gewinnen. Dazu diente ein Moleskine Smart Pen (NWP-F130). Da die verfügbare NeoSmartpen-Websoftware keine geeignete Python-Schnittstelle für die Datenerfassung bereitstellte, analysierten wir die TypeScript-Implementierung des NeoSmartpen Web SDK 2.0 (Neo smartpen, 2023) und implementierten das benötigte Bluetooth-Low-Energy-Protokoll in Python. Der daraus entstandene Logger führt den Verbindungsaufbau mit dem Stift durch, aktiviert das Online-Streaming, dekodiert das binäre Paketformat und zeichnet Ereignisse für das Aufsetzen, Bewegen und Abheben des Stifts

sowie Hover-Ereignisse zusammen mit Geräte- und lokalen Zeitstempeln auf. Der Stift liefert diese Ereignisse mit etwa 80 bis 90 Hz. Koordinaten, Druck und Neigung wurden zu Diagnosezwecken gespeichert; die zeitlichen Stiftereignisse bildeten die Grundlage der in dieser Arbeit verwendeten Labels.

Die Eingabedaten des Modells wurden unabhängig davon durch eine Apple Watch Series 6 am Schreibhandgelenk der Versuchsperson aufgezeichnet. Erfasst wurden der dreiachsige Beschleunigungssensor und das dreiachsige Gyroskop, zunächst mit 50 Hz. Nach den ersten neun Aufnahmen wurde die Erfassung auf 100 Hz umgestellt und zusätzlich der von Core Motion getrennt ausgegebene Schwerkraftvektor gespeichert, der die Orientierung des Handgelenks rekonstruierbar macht. Aus dieser Umstellung ergeben sich die beiden Datenpools aus Abschnitt 3.3.

Für erste Testaufnahmen wurde die Anwendung SensorLogger (Sensor Logger, 2026) verwendet, die in unseren Versuchen jedoch nur eine effektive Abtastrate von etwa 20 Hz erreichte und keine Kontrolle über Zeitstempel und Übertragung bot. Wir haben deshalb eine eigene native Anwendung für watchOS und iOS in Swift entwickelt. Auf der Watch erfasst ein auf CMMotionManager aus dem Core-Motion-Framework (Apple Inc., 2026a) basierender Dienst die Gerätebewegung und bündelt je zehn Messungen zu einem Paket, das über WatchConnectivity (Apple Inc., 2026b) an die iPhone-App und von dort per HTTP an den Erfassungsserver geht. Jedes einzelne Sample trägt dabei einen Zeitstempel der Uhr selbst, jedes Paket eine fortlaufende Sequenznummer. Beides ist notwendig, weil die Watch bei Verbindungsproblemen puffert und Pakete verspätet nachliefert: Die Ankunftszeit am Server ist um Sekunden bis Minuten verschoben, während der Sample-Zeitstempel korrekt bleibt. Alle Zeitrechnungen in dieser Arbeit laufen deshalb auf dieser Capture-Uhr der Watch (Abschnitt 4.1).

3.2 Studienprotokoll

Jede Aufnahme lief unter einem festen Ablaufskript, das ein Protokoll-Runner im Erfassungsserver steuerte. Die Versuchsperson sah auf einem Bildschirm die aktuelle Aufgabe mit Countdown und Anweisung, die Versuchsleitung überwachte den Lauf auf einem zweiten Gerät. Jeder Aufgabenwechsel wurde mit einem Zeitstempel als Marker protokolliert. Die Marker gehen nicht in das Training ein, sie erlauben aber im Nachhinein, jeden Vorhersagefehler einer konkreten Aufgabe zuzuordnen (Abschnitt 6.4).

Protokoll v1 (Abbildung 1) bestand aus drei Schreibaufgaben von je 240 s, getrennt durch zwei freie Pausen von je 90 s. In den Pausen durften die Personen tun, was sie wollten, nur nicht schreiben. Die Auswertung der ersten Aufnahmen zeigte, dass diese Pausen als Negativbeispiele zu leicht waren: Das Modell lehnte sie fast fehlerfrei ab, und die wenigen Fehler konzentrierten sich auf Personen, die in der Pause auf dem Handy tippten. Diese Bewegung erzeugt am Handgelenk ein schreibähnliches Muster, das im Protokoll weder vorgesehen noch kontrolliert war.




Abbildung 1: Protokoll v1: drei Schreibaufgaben (blau) von je 240 s, getrennt durch zwei freie Pausen (grau) von je 90 s. Die Blockbreite entspricht der Dauer.

Protokoll v2 (Abbildung 2) ersetzt die freien Pausen deshalb durch fünf gezielte Hard Negatives: Tippen auf dem Handy, Scrollen auf dem Handy, Tippen auf einer Tastatur, Herumspielen mit dem Stift in der Schreibhand und Gestikulieren beim Erzählen. Auf der Schreibseite kommen zwei Varianten hinzu, die den beobachteten Schwierigkeiten entsprechen: bewusst leises, druckarmes Schreiben und Schreiben mit erzwungenen Denkpausen von 10 bis 15 s. Schreib- und Nicht-Schreibaufgaben wechseln sich ab; ein Durchlauf dauert etwa 25,5 min.




Abbildung 2: Protokoll v2: fünf Schreibaufgaben (blau, 150 bis 210 s) im Wechsel mit sechs Nicht-Schreibaufgaben (grau, 60 bis 120 s), davon fünf gezielte Hard Negatives. Die Blockbreite entspricht der Dauer.

Die Reihenfolge der Aufgaben ist pro Person balanciert. Der Runner erzeugt für die Schreibaufgaben und getrennt für die Nicht-Schreibaufgaben je ein Balanced Latin Square nach Williams (1949), wählt die Zeile über einen fortlaufenden Personenindex und verschränkt beide Folgen. Die Sollzeiten werden pro Lauf summenerhaltend um bis zu $\pm 15\%$ variiert (Jitter), damit Aufgabengrenzen nicht bei allen Personen an denselben Zeitpunkten liegen. Vor jeder Aufgabe lief ein Countdown von 5 s, in dem die Anweisung gelesen werden konnte.

3.3 Datensatz

In den Datensatz gingen nur vollständig abgeschlossene Aufnahmen ein. Pilotläufe, Kurztests und abgebrochene Durchläufe wurden ausgeschlossen. Jede verbleibende Aufnahme wurde vor der Übernahme auf drei Punkte geprüft: eine Abtastrate innerhalb von $\pm 20\%$ um den Sollwert und eine lückenlose Sequenznummerierung des Watch-Stroms, eine zeitliche Überlappung beider Datenströme über die gesamte Sitzung sowie eine Zeitausrichtung von Stift und Watch, die entweder automatisch als vertrauenswürdig eingestuft wurde oder eine manuelle Prüfung der Alignment-Kurven bestand (Abschnitt 4.1). Eine v2-Aufnahme

fiel dabei heraus, weil sich für sie kein belastbarer Zeitversatz bestimmen ließ. Pro Person wurde genau eine Aufnahme verwendet. Der finale Datensatz umfasst 32 Personen, 13 nach Protokoll v1 und 19 nach Protokoll v2, mit insgesamt rund 11,5 Stunden annotierter Sensordaten. Die beiden Autoren sind als Versuchspersonen enthalten, die übrigen Personen waren überwiegend Studierende und Bekannte. Die Watch saß in allen Aufnahmen am Schreibhandgelenk; Händigkeit wurde nicht systematisch erfasst und geht nicht als Variable ein.

Tabelle 1: Zusammensetzung des Datensatzes. Der Modern-Pool ist eine echte Teilmenge des Legacy-Pools: Aufnahmen mit 100 Hz wurden für den Legacy-Pool auf 50 Hz heruntergerechnet, damit alle 32 Personen in einem Protokoll auswertbar sind.

Pool	Personen	Abtaste	Werte je Sample	Inhalt
Legacy	32	50 Hz	6	alle Aufnahmen (9 nativ, 23 dezimiert)
Modern	23	100 Hz	9	ab Ende Mai 2026, mit Schwerkraftvektor
<i>Protokoll: 13 Personen v1 (15,5 min), 19 Personen v2 (25,6 min)</i>				
<i>Fenster (1 s, Schritt 0,5 s, Legacy): 81 938, davon 42,7 % Schreiben</i>				
<i>Schreibanteil je Person: 44,4 % $\pm$ 8,4 Prozentpunkte</i>				
<i>Alignment-Konfidenz σ: -2,19 bis -5,10 (Median -4,1)</i>				

Die Umstellung auf 100 Hz mit Schwerkraftvektor teilt den Datensatz in zwei Pools (Tabelle 1). Damit alle Personen in einem einheitlichen Protokoll vergleichbar bleiben, haben wir die 100-Hz-Aufnahmen mit einem Anti-Aliasing-Filter (Chebyshev-Tiefpass achter Ordnung, phasenneutral) auf 50 Hz heruntergerechnet und den Schwerkraftvektor verworfen. Dieser Legacy-Pool mit 32 Personen ist die Grundlage aller Hauptergebnisse; der Modern-Pool mit 23 Personen dient den Ablationen zu Abtaste und Schwerkraftvektor. Da der Modern-Pool eine Teilmenge des Legacy-Pools ist, sind gepaarte Vergleiche nur innerhalb eines Pools zulässig.

Über alle 32 Personen tragen 42,7 % der Fenster das Label Schreiben, die Klassen sind also nahezu ausgeglichen. Je Person liegt der Schreibanteil bei 44,4 % mit einer Streuung von 8,4 Prozentpunkten, weil Schreibtempo und Länge der Denkpausen sich stark unterscheiden.

3.4 Forschungsethik und Umgang mit den Daten

Alle Versuchspersonen nahmen freiwillig teil und unterschrieben vor der Aufnahme eine Einwilligungserklärung, die Zweck der Erhebung, Art der erfassten Daten, geplante Verwendung und das Recht benennt, die Aufnahme jederzeit ohne Angabe von Gründen abubrechen. Rekrutiert wurde im Studierenden- und Bekanntenumfeld der Autoren; eine Vergütung oder eine Anrechnung von Versuchspersonenstunden gab es nicht. Ein formales Ethikvotum wurde für dieses Semesterprojekt nicht eingeholt. Wir weisen das aus, statt es zu relativieren; die Erhebung verzichtet auf Interventionen, erfasst keine besonderen Kategorien personenbezogener Daten und beschränkt sich auf Bewegungsdaten des Handgelenks und Stiftereignisse während vorgegebener Aufgaben.

Die Aufnahmen sind pseudonymisiert. Jede Person erhält eine laufende Kennung, die im gesamten Datensatz und in diesem Bericht an die Stelle des Namens tritt; Namen und Kontaktdaten werden nicht zusammen mit den Kennungen aufbewahrt. Die Schreibaufgaben sind vorgegeben, sodass die Stiftdaten überwiegend keine selbst formulierten Inhalte enthalten. Die Ausnahme ist die Aufgabe freies Schreiben: Ihre Stiftkoordinaten könnten den geschriebenen Text rekonstruierbar machen. In die Auswertung gehen von den Stiftdaten ausschließlich die Zeitpunkte der Ereignisse Aufsetzen, Bewegen und Abheben ein, nie die Koordinaten. Rohdaten liegen ausschließlich lokal und sind von der Versionsverwaltung ausgeschlossen; im Bericht erscheinen sie nur aggregiert oder als kurzer Signalausschnitt. Für die gemeinsame Auswertung mit der Partnergruppe an der ETH Zürich wurden die pseudonymisierten Rohaufnahmen weitergegeben.

Demografische Angaben (Alter, Geschlecht, Händigkeit, Schreibgewohnheit) sieht das Protokoll nicht vor und wurden nicht erhoben. Wir können die Zusammensetzung der Kohorte deshalb nicht quantifizieren und Leistungsunterschiede nicht nach diesen Merkmalen aufschlüsseln. Bekannt ist nur, dass es sich überwiegend um Studierende handelt und dass die Uhr in allen Aufnahmen am Schreibhandgelenk saß. Für eine Aussage darüber, für wen der Detektor funktioniert, ist das eine Lücke; wir greifen sie in Abschnitt 8 auf.

4 Methodik

Abbildung 3 fasst die Verarbeitungskette zusammen. Aus Stift- und Watch-Strom entsteht zunächst ein Datensatz mit einem Label je Watch-Sample. Darauf bauen zwei Modellfamilien auf: ein Random Forest auf handgebauten Merkmalen über 1-s-Fenster und zeitliche Faltungsnetze auf den rohen Sequenzen über 5-s-Fenster. Ein Hidden-Markov-Modell glättet die Fenstervorhersagen zeitlich. Die folgenden Abschnitte beschreiben jede Stufe so weit, wie sie die Gültigkeit der Ergebnisse beeinflusst.




Abbildung 3: Verarbeitungskette. Der Stift wird nur links oben gebraucht; alles rechts davon läuft auf Watch-Daten allein. Das HMM ist auf dem Random Forest im Einsatz, für die Netze wurde es nur zur Kontrolle getestet (gestrichelt).

4.1 Zeitliche Ausrichtung und Ground-Truth-Labels

Stift und Watch haben keine gemeinsame Zeitbasis. Der Stift stempelt mit seiner eigenen Geräteuhr, die in unseren Geräten rund 922 Tage hinter der Wanduhr lag und zusätzlich einen sitzungsabhängigen Versatz von wenigen Sekunden aufwies. Ein Versatz von einer halben Sekunde entspricht bereits mehreren Buchstaben. Der Versatz δ wird deshalb pro Aufnahme aus den Daten selbst geschätzt, mit einem Verfahren, das uns Samuel Wehrli von der ETH Zürich als unveröffentlichte technische Notiz zur Verfügung gestellt hat (persönliche Mitteilung, 2026); es ist im Folgenden vollständig beschrieben, damit die Auswertung ohne diese Notiz nachvollziehbar bleibt. Die Annahme dahinter ist, dass das Handgelenk sich während eines Strichs als Ganzes vergleichsweise wenig bewegt, während die großen Translationsbewegungen (Greifen, Umblättern, Gestikulieren) zwischen den Strichen liegen. Für einen Kandidaten δ verschiebt das Verfahren die Strichintervalle des Stifts um δ und mittelt die gefensterter Varianz der Watch-Beschleunigung innerhalb dieser Maske; das richtige δ minimiert diesen Wert. Gesucht wird zweistufig, grob über ± 20 s und fein über ± 5 s. Als Konfidenzmaß dient der z-Wert des Minimums gegenüber der Verteilung auf dem Suchgitter (σ); je negativer, desto ausgeprägter das Minimum. Abbildung 4 zeigt das Ergebnis an einer Aufnahme.




Abbildung 4: Zeitliche Ausrichtung am Beispiel von Person P13. Links: normierte Varianz der Watch-Beschleunigung mit den um δ^* verschobenen Strichintervallen (grün); die Striche liegen in den Tälern. Mitte und rechts: mittlere Varianz unter der Maske als Funktion von δ , in Grob- und Feinsuche.

Wir übernehmen δ , wenn $\sigma \leq -2$ gilt, das Minimum nicht am Rand des Suchraums liegt und $|\delta| \leq 5$ s ist. Die letzten beiden Regeln kamen im Lauf des Projekts hinzu, weil ein formal akzeptables σ nicht ausschließt, dass die Zielfunktion einfach zum Rand hin abfällt; in zwei Aufnahmen hatte ein solches Randminimum die Labels um 16 bzw. 18 s verschoben. Mehr als fünf Sekunden Versatz sind physikalisch ausgeschlossen, weil beide Zeitstempel gegen dieselbe Wanduhr laufen.

Nach der Ausrichtung entsteht der Datensatz durch einen Merge mit der Watch als Basis: Jedes Watch-Sample erhält das Label 1, wenn innerhalb von ± 40 ms ein Stiftereignis vom Typ *aufgesetzt* oder *bewegt* liegt, sonst das Label 0. Watch-Samples ohne Stiftereignis in Reichweite bilden damit die Negativklasse, und zwar sowohl in den Nicht-Schreibaufgaben als auch in den Lücken innerhalb der Schreibaufgaben. Der Merge läuft auf der Capture-Uhr der Watch; eine frühere Fassung auf der Ankunftszeit am Server hatte Labels nachgelieferter Pakete um bis zu 42 s versetzt.

4.2 Vorverarbeitung und Fensterbildung

Die rohen Stiftlabels sind für die Zielgröße zu hart. Zwischen Buchstaben, an Wortgrenzen und in kurzen Denkpausen hebt der Stift für 50 ms bis 2 s ab, und die Handgelenkbewegung in diesen Lücken unterscheidet sich nicht von der in den Strichen davor und danach. Wir schließen deshalb auf Sample-Ebene alle Lücken bis 2,5 s zwischen zwei Schreibabschnitten (morphologisches Schließen). Die Zielgröße ist damit ausdrücklich *im Schreibmodus sein* einschließlich Mikropausen und nicht *Stift berührt gerade das Papier*. Der Wert von 2,5 s stammt aus einem Sweep über Schwellen von 0,3 bis 3,0 s und war dort das Optimum; oberhalb von 2,5 s ändert sich die Genauigkeit nicht mehr nennenswert. Das Öffnen kurzer Schreibspitzen haben wir getestet, aber nicht verwendet, weil echte kurze Striche wie i-Punkte und Satzzeichen informativ sind.

Anschließend werden gleitende Fenster mit halber Fensterlänge als Schritt gebildet; ein Fenster trägt das Label Schreiben, wenn mindestens 60 % seiner Samples als Schreiben gelabelt sind. Auch die Fensterlänge haben wir durchgetestet (1 bis 10 s). Für den Random

Forest ist 1 s die beste Wahl, lang genug für die Spektralmerkmale und zeitlich noch scharf; die Netze arbeiten auf 5-s-Fenstern, wo ihre Genauigkeit ein Plateau erreicht. Die Zeitskala, auf der eine Entscheidung berichtet wird, behandeln wir davon getrennt (Abschnitt 4.5).

4.3 Merkmalsbasierte Klassifikation

Je 1-s-Fenster berechnen wir 88 Merkmale aus den sechs Kanälen (Tabelle 2). Die Gruppen decken die Amplitude, das Frequenzspektrum, die Glattheit und die Kopplung der Achsen ab. Beim Spektrum wird der Gleichanteil vor Schwerpunkt und Entropie entfernt; das Band von 3 bis 8 Hz entspricht der typischen Strichfrequenz beim Schreiben. Die Jerk-Merkmale werden mit der Abtastrate skaliert, damit sie zwischen 50 und 100 Hz vergleichbar bleiben. Im Modern-Pool kommen vier Merkmale aus dem Schwerkraftvektor hinzu (mittlere Neigung je Achse und mittlere Winkeländerung zwischen aufeinanderfolgenden Schwerkraftvektoren).

Tabelle 2: Merkmalsgruppen je 1-s-Fenster (Legacy-Pool, 88 Merkmale).

Gruppe	Inhalt	Anzahl
Zeitstatistik	Mittel, Std., Min., Max., RMS, Spanne je Achse	36
Spektrum	dominante Frequenz, Schwerpunkt, Entropie, Anteil 3 bis 8 Hz je Achse	24
Jerk	Std. und mittlerer Betrag der Ableitung, Beschleunigungsachsen und Beträge	8
Nulldurchgänge	Rate je Achse	6
Beträge	Mittel, Std., Energie von $\ a\ $ und $\ \omega\ $	6
Korrelation	Pearson-Korrelation der Achsenpaare innerhalb Beschleunigung und Gyroskop	6

Das schwierigste Problem beim Übertragen auf fremde Personen ist nicht, welches Merkmal Schreiben anzeigt, sondern dass dieselbe Geste an verschiedenen Handgelenken unterschiedliche Absolutwerte erzeugt (Handgelenksumfang, Sitz der Uhr, Schreibhaltung). Wir standardisieren deshalb jede Merkmalsspalte je Aufnahme (z-Score), bevor ein Modell sie sieht. Dieser Schritt war der größte Einzelgewinn auf der Merkmalsseite und reduzierte zugleich die Streuung zwischen den Folds deutlich. Für den Live-Einsatz ist er nicht kausal, weil die Statistik einer Aufnahme auch deren Zukunft enthält; eine einsetzbare Variante schätzt Mittel und Streuung auf den Trainingspersonen und schneidet im gepaarten Vergleich nicht schlechter ab.

Als Klassifikator dient ein Random Forest (Breiman, 2001) mit 200 Bäumen und klassenbalancierten Gewichten in der Implementierung von scikit-learn (Pedregosa et al., 2011); die Entscheidung fällt bei einer Wahrscheinlichkeit von 0,5. Extra Trees, Gradient Boosting, logistische Regression, ein mehrschichtiges Perzeptron und eine SVM mit RBF-Kern auf denselben Folds übertrafen ihn nicht.

4.4 Deep-Learning-Modelle

Neben den handgebauten Merkmalen haben wir Netze direkt auf den rohen Sequenzen der sechs Kanäle trainiert. Nach einer breiteren Suche über eindimensionale CNNs, LSTM- und GRU-Netze, InceptionTime (Ismail Fawaz et al., 2020), Transformer-Varianten und mehrere Hybride blieben zwei Architekturen für den Endvergleich:

- **tcn6**: ein zeitliches Faltungsnetz nach Bai, Kolter, and Koltun (2018) mit sechs Ebenen dilatierter, kausaler Faltungen. Das rezeptive Feld deckt mit 253 Samples nahezu das ganze 5-s-Fenster ab. Die Ausgabe wird über die Zeit gemittelt und linear auf die zwei Klassen abgebildet; rund 9 400 Parameter.
- **tcn_bigr**: derselbe Faltungsstamm, dessen Ausgabefolge statt in ein Mittel in eine bidirektionale GRU-Schicht (Chung, Gulcehre, Cho, & Bengio, 2014) läuft. Die Rekursion übernimmt die zeitliche Zusammenfassung, die tcn6 wegmittelt, und der Rückwärtslauf trägt das Fensterende in frühe Zeitschritte. Innerhalb eines abgeschlossenen Fensters ist das zulässig, über Fenstergrenzen hinweg bleibt das Modell kausal; rund 19 000 Parameter.

Beide Netze verzichten auf die Normalisierung je Aufnahme, weil die Batch-Normalisierung die Skala ohnehin neu setzt. Trainiert wurde mit Adam, Kreuzentropie und Early Stopping auf einem personenfremden Validierungsanteil in PyTorch (Paszke et al., 2019). Die Hyperparameter stammen aus einer Rastersuche mit identischem Raster für alle Architekturen, damit keine Architektur durch bessere Abstimmung bevorzugt wird; jede Endkonfiguration wurde mit drei Zufallssaaten trainiert.

Zwei weitere Modellfamilien dienten als Kontrolle, ob die beobachtete Leistungsgrenze an der Modellklasse hängt. MiniRocket (Dempster, Schmidt, & Webb, 2021) klassifiziert Zeitreihen mit einer großen Zahl zufälliger Faltungskerne und einem linearen Kopf, lernt die Merkmale also gerade nicht. Harnet (Yuan et al., 2024) ist ein auf 700 000 Personentagen Beschleunigungsdaten selbstüberwacht vortrainiertes Netz, das wir als eingefrorenen Merkmalsextraktor mit logistischer Regression einsetzen. Beide laufen auf 5-s-Fenstern, harnet auf 30 Hz und nur auf den drei Beschleunigungsachsen.

4.5 Zeitliche Glättung und Modellfusion

Ein Fenster von einer Sekunde ist die richtige Größe für die Merkmale, aber nicht die Zeitskala, auf der ein Nutzer eine Aussage erwartet. Ein Schreibzeit-Tracker fragt, ob jemand in den letzten Sekunden bis Minuten geschrieben hat. Wir unterscheiden deshalb das Merkmalsfenster von der Entscheidungsskala und berichten jedes Modell auf mehreren Skalen. Die einfachste Glättung ist ein gleitender Mittelwert der Fensterwahrscheinlichkeiten über 5, 10 oder 30 s, danach erneut bei 0,5 geschwellt. Wir rechnen ihn ausschließlich rückwärts gerichtet, also nur aus Vergangenheit und Gegenwart, damit die Zahlen dem entsprechen, was ein Tracker zum Zeitpunkt t tatsächlich anzeigen kann.

Der eigentliche Glätter ist ein Hidden-Markov-Modell mit den zwei Zuständen Nicht-Schreiben und Schreiben (Rabiner, 1989). Die Idee dahinter ist einfach: Schreiben kommt in Blöcken vor, nicht in einzelnen Sekunden. Ein Fenster, das für sich genommen unsicher aussieht, das aber zwischen zwei klar erkannten Schreibfenstern liegt, gehört mit hoher Wahrscheinlichkeit ebenfalls zum Schreiben. Das HMM formalisiert genau diese Überlegung. Es bekommt die Wahrscheinlichkeit des Random Forest je Fenster als Beobachtung und lernt aus den Trainingspersonen nur, wie wahrscheinlich ein Zustandswechsel von einem Fenster zum nächsten ist. Die gelernte Matrix ist träge (Verbleibwahrscheinlichkeit 0,97 in beiden Zuständen), was einem Gedächtnis von etwa 16 bis 18 s entspricht. Das Modell hält damit bei schwacher Evidenz den Zustand und wechselt erst, wenn die Beobachtungen deutlich dagegen sprechen.

Entscheidend ist, welchen Teil der Aufnahme das HMM dabei sehen darf. Der Vorwärtsfilter nutzt nur Vergangenheit und Gegenwart und ist damit live einsetzbar. Der Vorwärts-Rückwärts-Smoother und der Viterbi-Pfad sehen die ganze Aufnahme und eignen sich für eine rückblickende Tagesauswertung. Als Negativkontrolle dekodieren wir zusätzlich mit innerhalb jeder Aufnahme zufällig permutierten Beobachtungen: Erkennt das HMM nur die Blockstruktur der Labels, bliebe die Genauigkeit hoch; ist der Gewinn signalgetrieben, fällt sie auf Zufallsniveau.

Als Modellfusion haben wir das Mittel der Wahrscheinlichkeiten zweier Modelle auf denselben 5-s-Fenstern getestet, sowohl zwischen den Familien (Random Forest mit tcn6) als auch zwischen zwei Netzen. Als Vorabtest dient die Korrelation der Residuen: Irren beide an denselben Fenstern, kann das Mittel wenig gewinnen.

5 Versuchsaufbau und Evaluation

5.1 Evaluationsprotokoll

Die Forschungsfrage verlangt, dass ein Modell auf Personen funktioniert, die es nie gesehen hat. Alle Kennzahlen stammen deshalb aus einer gruppierten fünffachen Kreuzvalidierung über die Personen, auf die wir uns mit der Partnergruppe an der ETH Zürich verständigt haben: In jeder Runde liegen sämtliche Fenster einer Person entweder im Training oder im Test, nie in beiden. Jede der 32 Personen ist genau einmal Testperson. Der Splitter ist eine eigene Implementierung und nicht scikit-learns GroupKFold: Die Personenkennungen werden mit einer festen Zufallssaat gemischt und anschließend reihum auf fünf Gruppen verteilt, was gleich große Folds ergibt. Die Gruppenreinheit ist dieselbe wie bei GroupKFold, die konkrete Zuordnung der Personen zu den Folds ist es nicht. In den ersten Erhebungsrunden hatten wir Leave-One-Subject-Out verwendet; beide Protokolle lieferten auf denselben Daten praktisch identische Werte.

Aus den Testrunden entsteht eine vollständige Out-of-Fold-Tabelle mit einer Wahrscheinlichkeit je Fenster. Die zeitliche Glättung, die Kalibrierung und die Fehleranalyse rechnen auf dieser Tabelle und erben damit dieselbe Leakage-Garantie; die Übergangsmatrix des HMM wird je Runde nur aus den Trainingspersonen geschätzt. Personenbezogene Kenn-

zahlen berichten wir als Mittel und Standardabweichung über die 32 Personen.

5.2 Metriken und statistische Analyse

Primäre Kennzahl ist die Genauigkeit je Fenster bei einer festen Schwelle von 0,5; sie ist hier aussagekräftig, weil die Klassen nahezu ausgeglichen sind und ein Tracker am Ende eine Entscheidung treffen muss. Ergänzend berichten wir die ROC-AUC als schwellenfreies Maß der Trennbarkeit und den F1-Wert der Klasse Schreiben. Jede Kennzahl steht zusammen mit ihrer Entscheidungsskala: je 1-s-Fenster, nach kausaler Glättung über 5, 10 und 30 s oder nach dem HMM.

Die Streuung zwischen Personen liegt bei drei bis vier Prozentpunkten. Unterschiede unterhalb dieser Größe sind ohne gepaarten Test nicht interpretierbar. Wir prüfen deshalb jeden Vergleich auf denselben Personen mit dem Wilcoxon-Vorzeichen-Rang-Test (Wilcoxon, 1945) auf den personenweisen Differenzen und geben an, bei wie vielen der 32 Personen eine Konfiguration vorn liegt. Ein Gewinn unter einem Prozentpunkt ohne $p < 0,05$ gilt als Rauschen. Für die Netze mitteln wir drei Zufallssaaten, weil selbst zwei Läufe derselben Konfiguration mit identischer Saat auf der GPU um bis zu 1,6 Prozentpunkte auseinanderliegen können. Rangfolgen aus Einzelläufen sind deshalb nicht belastbar; bei 32 Personen liegen für die Netze nur Saaten-Aggregate vor, der Vergleich der Netze untereinander ist dort also nominal.

Modellauswahl und Evaluation auf derselben Kohorte. Architekturen und Hyperparameter wurden anhand derselben gruppierten Kreuzvalidierung ausgewählt, auf der wir am Ende die Leistung berichten. Personen kreuzen dabei nie zwischen Training und Test, es liegt also keine Leakage auf Fensterebene vor, wohl aber eine Selektionsoptimierung: Aus mehreren Konfigurationen wurde diejenige mit dem besten Kreuzvalidierungswert übernommen und deren Wert anschließend als Ergebnis berichtet. Eine verschachtelte Kreuzvalidierung oder ein unabhängiger Bestätigungssatz hätte das ausgeschlossen; beides war mit 32 Personen und dem Rechenbudget des Projekts nicht darstellbar. Die Zahlen der Netze sind deshalb als Ergebnis einer explorativen Modellauswahl zu lesen und nach oben verzerrt. Ein Anhaltspunkt für die Größe dieser Verzerrung: Die Sieger der Hyperparametersuche verloren beim Nachrechnen mit drei Saaten ein bis zwei Prozentpunkte gegenüber ihrem besten Einzellauf innerhalb der Suche. Für den Random Forest ist der Effekt gering, weil seine Hyperparameter über das ganze Projekt unverändert blieben.

5.3 Baselines und Ablationsstudien

Der Random Forest auf 88 Merkmalen ist die Referenz, gegen die alle anderen Ergebnisse gelesen werden. Weil die Netze auf nativen 5-s-Fenstern arbeiten, vergleichen wir sie mit ihm bei gleicher Entscheidungslatenz: gegen seine kausal über 5 s geglätteten 1-s-Vorhersagen und gegen einen Random Forest, dessen Merkmale direkt über 5 s berechnet wurden.

Die Ablationen beantworten je eine Frage mit einer einzigen Variablen auf identischen Folds und Saaten: Schwerkraftvektor (sechs gegen neun Eingangswerte je Sample im Modern-

Pool), Abtastrate (50 gegen 100 Hz), Gyroskop (volle IMU gegen nur Beschleunigung), Dekodiermodus (gleitender Mittelwert gegen HMM-Filter gegen HMM-Smoother) und Fusion zweier Modelle. Weitere Eingriffe, die sich als wirkungslos erwiesen haben, fasst Abschnitt 6.3 zusammen: Rhythmusmerkmale, geschärfte Merkmale und Umgewichtung für die Tipp-Aufgaben, Datenaugmentation, eine breite automatische Merkmalsbank, ein personenspezifischer Schwellwert und ein Audit der zeitlichen Ausrichtung. Wir berichten diese Nullbefunde, weil sie zusammen die Interpretation der Leistungsgrenze tragen.

Random Forest, HMM und Nachverarbeitung laufen lokal in unter einer Stunde. Die Netze wurden auf einer gemieteten GPU (RTX 4000 Ada) trainiert; ein vollständiger Durchlauf mit drei Saaten über beide Pools benötigte rund zehn Stunden.

6 Ergebnisse

6.1 Klassifikation der Schreibaktivität

Tabelle 3 fasst die Hauptergebnisse auf dem Legacy-Pool mit 32 Personen zusammen. Der Random Forest erreicht je 1-s-Fenster eine Genauigkeit von 0,865 und eine ROC-AUC von 0,942, gemittelt über die 32 ausgelassenen Personen. Der kausale HMM-Filter hebt dieselben Vorhersagen ohne Neutrainig auf 0,898. Den höchsten beobachteten Mittelwert erreicht tcn_bigru auf nativen 5-s-Fenstern mit 0,921 bei einer ROC-AUC von 0,975. Dieser Wert ist ein Mittel über drei Zufallssaaten und nicht gepaart gegen den Random Forest getestet; die beiden Streuungsangaben in Tabelle 3 messen Verschiedenes.

Tabelle 3: Hauptergebnisse, Legacy-Pool, 32 Personen, gruppierte fünffache Kreuzvalidierung. Die letzte Spalte nennt, worüber die Streuung gebildet ist: Bei Random Forest und HMM ist $\pm$ die Standardabweichung zwischen den 32 Personen, bei den Netzen die Standardabweichung über drei Zufallssaaten des Mittels der fünf Gruppen. Die beiden Größen messen Verschiedenes und sind nicht gegeneinander lesbar; für die Netze wurden auf dieser Kohorte keine personenweisen Vorhersagen gespeichert. Kausal bedeutet, dass die Entscheidung zum Zeitpunkt t nur Daten bis t verwendet.

Modell	Entscheidungsskala	kausal	Genauigkeit	ROC-AUC	$\pm$ über
Random Forest	1 s	ja	$0,865 \pm 0,035$	$0,942 \pm 0,029$	32 Personen
Random Forest, Burst	5 s	ja	$0,861 \pm 0,037$	$0,934 \pm 0,027$	32 Personen
Random Forest, Burst	30 s	ja	$0,773 \pm 0,041$	$0,856 \pm 0,040$	32 Personen
Random Forest + HMM-Filter	~ 18 s, adaptiv	ja	$0,898 \pm 0,034$	$0,962 \pm 0,025$	32 Personen
Random Forest + HMM-Smoother	rückblickend	nein	$0,917 \pm 0,036$	$0,973 \pm 0,025$	32 Personen
tcn6	5 s nativ	ja	$0,915 \pm 0,007$	0,974	3 Saaten
tcn_bigru	5 s nativ	ja	$0,921 \pm 0,006$	0,975	3 Saaten

Der F1-Wert der Klasse Schreiben liegt für den Random Forest bei $0,839 \pm 0,028$ und nach dem HMM-Filter bei 0,884. Die Streuung zwischen Personen ist mit 3,5 Prozentpunkten die größte Unsicherheitsquelle; Abbildung 5 zeigt sie aufgelöst. Die Genauigkeit reicht von 0,78 (P73, P31, P63) bis 0,91 (P26, P13, P57, P66). Der HMM-Filter verbessert alle 32 Personen, die schwächsten aber unterschiedlich stark; darauf kommen wir in der Fehler-

analyse zurück.




Abbildung 5: Genauigkeit je ausgelassener Person, aufsteigend sortiert nach dem Random Forest auf 1-s-Fenstern (Balken). Punkte: derselbe Random Forest nach kausalem HMM-Filter, Dreiecke: nach rückblickendem HMM-Smoother. Die gepunktete Linie ist das Mittel des Random Forest.

Der ehrliche Vergleich zwischen Merkmalsmodell und Netz hält die Entscheidungs-latenz fest. Bei einem Fenster von 5 s liegt tcn_bigru mit 0,921 sechs Prozentpunkte über dem kausal auf 5 s geglätteten Random Forest (0,861) und noch 2,3 Prozentpunkte über dem HMM-gestützten Random Forest, der mit rund 18 s deutlich mehr Kontext verbraucht. Dieser Abstand ist kein Effekt des längeren Eingangsfensters allein: Ein Random Forest, dessen 88 Merkmale direkt über 5 s berechnet werden, kam auf 20 Personen auf 0,879 und lag damit gepaart signifikant unter tcn6 (0,898, $p = 0,0012$ über 15 Personen in der ersten Messung). Das Netz nutzt die Zeitstruktur innerhalb des Fensters, die die Merkmalsstatistik wegmittelt. Auf 1-s-Fenstern ist der Vorsprung der Netze dagegen fast vollständig hochfrequentes Rauschen, das die Glättung ohnehin entfernt (TCN 0,895 gegen Random Forest 0,872 je Fenster, nach Glättung über 5 s nicht mehr unterscheidbar).




Abbildung 6: Genauigkeit in Abhängigkeit von der Zahl der Personen im Datensatz. Der Random Forest bewegt sich zwischen 20 und 32 Personen nicht, beide Netze steigen um mehr als ihre Saatenstreuung.

Die Kohorte ist im Lauf des Projekts von 3 auf 32 Personen gewachsen, und diese Reihe ist selbst ein Ergebnis (Abbildung 6). Der Random Forest liegt bei 20, 22 und 32 Personen bei 0,869, 0,863 und 0,865, also innerhalb des Rauschens; auch die früheren Stufen mit 7 bis 15 Personen lagen zwischen 0,86 und 0,87. Zwölf zusätzliche Personen haben ihn nicht bewegt. Die Netze legen im selben Schritt von 22 auf 32 Personen um 0,7 (tcn6) und 0,95 Prozentpunkte (tcn_bigru) zu, jeweils mehr als ihre Saatenstreuung. Die Ergebnisse deuten damit darauf hin, dass die Grenze des Random Forest eher in der Repräsentation als in der Datenmenge liegt. Ein kausaler Schluss ist das nicht: Zwischen den Stufen hat sich nicht nur die Zahl der Personen geändert, sondern auch die Zusammensetzung der Kohorte und der Anteil der Aufnahmen nach Protokoll v2 mit seinen schwierigeren Gegenaufgaben. Denkbar ist deshalb auch, dass der Random Forest einen Zugewinn durch zusätzliche Personen gegen die härtere Aufgabenmischung eintauscht und beides sich zu einer flachen Kurve addiert.

Der Vorsprung von tcn_bigru gegenüber tcn6 (0,55 Prozentpunkte bei einer Saatenstreuung von 0,6 bis 0,7) ist nominal und nicht belegt; im Modern-Pool dreht sich die Rangfolge. Alle übrigen in der Suche getesteten Netze, darunter ein zweischichtiges GRU, InceptionTime und zwei Transformer-Varianten, lagen auf 20 Personen zwischen 0,88 und 0,93 und damit im selben Band oder darunter; die Transformer waren am schwächsten. Die Kontrollfamilien bestätigen das Bild von der anderen Seite: MiniRocket erreicht auf 5-s-Fenstern exakt den Wert des Random Forest auf 5-s-Merkmalen (0,886 gegen 0,885, $p = 0,93$ auf 15 Personen), und das vortrainierte harnet liegt als eingefrorener Merkmalsextraktor gleichauf mit dem Random Forest, wobei seine Fehler über die Personen mit denen des Random Forest zu $r = 0,85$ korrelieren.

6.2 Zeitliche Glättung

Abbildung 7 stellt die Dekoder auf denselben Wahrscheinlichkeiten gegenüber. Der kausale gleitende Mittelwert hebt die Genauigkeit auf keiner Skala über das 1-s-Niveau; bei 5 s liegt er gleichauf, bei 30 s neun Prozentpunkte darunter, weil er echte Übergänge verschmiert. Das HMM tut das Gegenteil: Der kausale Vorwärtsfilter gewinnt gegenüber dem rohen 1-s-Modell 3,3 Prozentpunkte Genauigkeit und 2,0 Punkte ROC-AUC, in 32 von 32 Personen ($p < 10^{-5}$). Er ist dabei kein verstecktes langes Fenster: Bei vergleichbarem Gedächtnis liegt der Mittelwert sieben bis zwölf Punkte darunter. Der Unterschied ist, dass der Filter bei schwacher Evidenz den Zustand hält und bei starker Evidenz schnell wechselt, statt fest zu mitteln. Die Negativkontrolle mit permutierten Beobachtungen fällt auf 0,516 und schließt aus, dass das HMM nur die Blockstruktur der Labels belohnt.




Abbildung 7: Genauigkeit derselben Random-Forest-Wahrscheinlichkeiten unter verschiedenen Dekodern (32 Personen, Mittel und Standardabweichung). Die Beschriftung am Balkenfuß gibt die Entscheidungszeit an. Grau: kausaler gleitender Mittelwert. Orange: kausaler HMM-Filter. Grün: rückblickende Dekoder, die die ganze Aufnahme sehen.

Der eigentliche Hebel ist der Dekodiermodus. Der rückblickende Smoothen liegt mit 0,917 um 1,9 Prozentpunkte über dem Filter, in 31 von 32 Personen ($p < 10^{-5}$); Viterbi liegt gleichauf. Eine Rastersuche über 450 Kombinationen der HMM-Parameter fand dagegen keinen Gewinner, der die Standardwerte signifikant schlägt. Für den Einsatz folgt daraus eine klare Trennung: Eine Live-Anzeige muss den Filter verwenden, eine rückblickende Tagesauswertung darf den Smoothen nehmen und gewinnt dadurch 1,9 Prozentpunkte ohne zusätzlichen Aufwand.

Ob der Gewinn an der Modellfamilie oder am Zeitkontext des Basismodells hängt, zeigt ein 2×2 -Versuch mit Random Forest und TCN auf 1-s- und 5-s-Fenstern: Das HMM hilft beiden 1-s-Modellen (+2,4 und +1,0 Punkte) und schadet beiden 5-s-Modellen (−0,8 und −0,9 Punkte). Sobald das Basismodell rund 5 s Kontext trägt, ist nichts mehr nachzurüsten. Random Forest mit HMM, TCN mit HMM und nativer 5-s-TCN landen auf denselben Personen an derselben Stelle (0,905, 0,905 und 0,911): Der Gewinn aus der Zeitstruktur lässt sich nachträglich oder in der Repräsentation einsammeln, aber nicht doppelt. Die Wahrscheinlichkeiten sind dabei gut kalibriert (erwarteter Kalibrierungsfehler 0,020 je 1-s-Fenster); der HMM-Filter hat den besten Brier-Score des Panels, ist aber leicht überkonfident.

6.3 Ergebnisse der Ablationsstudien

Schwerkraftvektor. Der Modern-Pool erlaubt den gepaarten Vergleich von sechs gegen neun Eingangswerten auf 23 Personen (Tabelle 4). Für tcn6 hilft der Schwerkraftvektor um 0,86 Prozentpunkte und halbiert die Saatenstreuung, für tcn_bigru ist er neutral. Auf vier Personen hatten wir zuvor für den Random Forest einen Verlust von 0,5 Punkten und für tcn_bigru auf sieben Personen einen Verlust von 2,7 Punkten gemessen; beide früheren Befunde waren Artefakte kleiner Stichproben. Die Orientierung des Handgelenks relativ zur Schwerkraft trägt also personenübergreifend Information, aber nur für die Architektur ohne rekurrenten Kopf. Plausibel ist, dass der bidirektionale Kopf eine vergleichbare

Lageinformation aus dem zeitlichen Verlauf rekonstruiert.

Tabelle 4: Ablation des Schwerkraftvektors im Modern-Pool (23 Personen, 100 Hz, 5-s-Fenster, Mittel $\pm$ Standardabweichung über drei Saaten).

Modell	6 Werte	9 Werte (mit Schwerkraft)	Δ
tcn6	$0,902 \pm 0,007$	$0,911 \pm 0,004$	+0,86 pp
tcn_bigru	$0,909 \pm 0,002$	$0,910 \pm 0,002$	+0,06 pp

Abtastrate. Ein explorativer Vergleich auf zwei nativ mit 100 Hz aufgezeichneten Aufnahmen derselben Person zeigt keinen Unterschied: Ein auf 50 Hz heruntergerechnetes Modell erreichte im Mittel 0,881, ein auf 100 Hz trainiertes 0,883. Eine Person und zwei Aufnahmen tragen keine allgemeine Aussage über den Wert der höheren Abtastrate. Der Befund ist mit dem Abtasttheorem verträglich, weil die 1-s-Merkmale und die Strichfrequenz von 3 bis 8 Hz bei 50 Hz vollständig abgedeckt sind, aber er ersetzt keinen personenübergreifenden Test. Die Erfassung läuft weiter mit 100 Hz, weil sich eine höhere Rate im Nachhinein nicht erzeugen lässt, eine niedrigere dagegen jederzeit. Umsonst ist das nicht: Datenmenge, Übertragung, Speicherbedarf und Energieverbrauch auf der Uhr verdoppeln sich, was für einen passiven Ganztags-Tracker der ausschlaggebende Punkt wäre.

Gyroskop. Ohne die 41 Gyroskop-Merkmale verliert der Random Forest auf 15 Personen 1,9 Prozentpunkte je 1-s-Fenster ($p = 0,003$), unter dem HMM-Filter noch 1,1 Punkte ($p = 0,008$), auf der 30-s-Skala 0,5 Punkte. Ein Modell allein aus Beschleunigungsdaten mit HMM (0,893) liegt damit über dem vollständigen Modell ohne HMM (0,874). Ersetzt man die fusionsbereinigte durch die rohe Gesamtbeschleunigung einschließlich Schwerkraft, wie sie die Hintergrund-Aufzeichnung der Watch liefert, ändert sich auf fünf Personen nichts ($\Delta = -0,2$ Punkte, nicht signifikant), weil die Schwerkraft innerhalb einer Sekunde nahezu konstant ist und die meisten Merkmale mittelwertfrei sind. Für die Netze ist der Preis höher: Mit nur drei Beschleunigungskanälen fällt tcn6 auf 23 Personen von 0,902 auf 0,884 und tcn_bigru von 0,909 auf 0,875. Der rekurrente Kopf lebt stärker vom Gyroskop als der Faltungstamm.

Fusion. Das Wahrscheinlichkeitsmittel aus Random Forest und tcn6 auf 5-s-Fenstern hebt auf 20 Personen beide Einzelmodelle signifikant (0,909 gegen 0,898 für tcn6, $p = 0,036$; gegen 0,879 für den Random Forest, $p = 0,003$), obwohl die Residuen mit $r = 0,60$ deutlich korrelieren. Zwei Netze untereinander (InceptionTime mit tcn_bigru) bringen dagegen nichts ($r = 0,71$, alle $p > 0,06$), ebenso wenig harnet mit dem Random Forest auf 14 Personen. Nur die Fusion über Paradigmengrenzen hinweg gewinnt, und auch sie nur rund einen Prozentpunkt.

Merkmale und Training. Fünf weitere Hebel auf der Seite des Random Forest blieben ohne Wirkung. Rhythmusmerkmale (Höhe des Autokorrelationsmaximums, spektrale Flach-

heit) sollten Tippen von Schreiben trennen und senkten die Falsch-positiv-Rate beim Tastaturtippen von 0,343 auf 0,336; die Genauigkeit blieb unverändert ($p = 0,54$). Zehn gezielt auf die Tipp-Verwechslung geschärfte Merkmale verschlechterten sie leicht (0,358). Eine dreifache Gewichtung der Tipp-Fenster im Training hob die Falsch-positiv-Rate beim Handytippen von 0,243 auf 0,286 und schadete den Personen, die Tippen bereits korrekt ablehnten; dasselbe Gewicht im Training von tcn6 machte das Netz global zurückhaltender, ohne gezielt Tippen zu trennen. Datenaugmentation der Rohsequenzen (Skalierung, Rotation, Zeitverzerrung, Jitter) brachte für tcn6 auf keinem Pool einen signifikanten Gewinn (alle $p > 0,07$, ROC-AUC durchweg flach). Ein personenspezifischer Schwellwert, auf dem ersten Drittel einer Aufnahme kalibriert, verschlechterte den F1-Wert (0,858 auf 0,846). Der einzige signifikante Merkmalsgewinn kam aus einer breiten automatischen Merkmalsbank: 42 aus rund 4700 tsfresh-Merkmalen destillierte Größen (Autokorrelation bei kurzen Verzögerungen, Quantile, Komplexitätsmaße) heben die Genauigkeit je Fenster um 0,5 Punkte ($p = 0,007$) und den Live-Pfad mit HMM um 0,4 Punkte ($p = 0,003$); wir haben sie wegen des geringen Effekts nicht in die Hauptpipeline übernommen.

Zeitliche Ausrichtung als Fehlerquelle. Ein Audit auf zehn Personen prüfte, ob der Restfehler der Ausrichtung die Leistungsgrenze erklärt. Weder die Konfidenz σ noch die Drift von δ zwischen erster und zweiter Aufnahmehälfte (Median 20 ms, entspricht einem Sample) korreliert mit der Genauigkeit der Person ($r = -0,22$ und $-0,18$). Die zwei damals schwächsten Personen hatten die schärfsten Minima. Ein künstlicher Fehler von ± 50 ms würde 10,7 % der Sample-Labels kippen; dass die Genauigkeit nicht mit den Alignment-Diagnosen zusammenhängt, belegt, dass dieser Fall im Merge nicht eintritt.

6.4 Fehleranalyse

Die Marker des Studienprotokolls erlauben, jeden Fehler einer Aufgabe zuzuordnen. Abbildung 8 zeigt für den Random Forest auf 1-s-Fenstern die Falsch-positiv-Rate je Nicht-Schreibaufgabe und die Falsch-negativ-Rate je Schreibaufgabe über alle 32 Personen.




Abbildung 8: Fehler je Aufgabe (Random Forest, 1-s-Fenster, 32 Personen). Links: Anteil der Nicht-Schreib-Fenster, die als Schreiben klassifiziert wurden. Rechts: Anteil der Schreib-Fenster, die als Nicht-Schreiben klassifiziert wurden.

Die Fehler verteilen sich nicht gleichmäßig. Pausen, Scrollen und Gestikulieren werden zu über 97 % korrekt abgelehnt. Die Falsch-positiv-Rate konzentriert sich auf das Tippen: 22 % der Tastatur-Fenster und 17 % der Handy-Fenster gelten als Schreiben, gegenüber 2,4 % in Pausen. Auf der Schreibseite ist das leise, druckarme Schreiben mit 29 % verpassten Fenstern die schwierigste Aufgabe, gefolgt von den Rechenaufgaben (22 %), in denen lange Denkpausen von mehr als 2,5 s die Schreibabschnitte zerschneiden.

Abbildung 9 zeigt, warum gerade das Tippen schwierig ist. Die Magnituden von Beschleunigung und Winkelgeschwindigkeit liegen beim Schreiben, in einer Pause und beim Tippen auf einer Tastatur in derselben Größenordnung. Was Schreiben auszeichnet, ist weniger die Amplitude als die zeitliche Struktur der Bewegung, und die ist beim Tippen ähnlich genug, um Fenster zu verwechseln.




Abbildung 9: Zwölf Sekunden Rohsignal der Apple Watch aus einer Aufnahme (Person P26): Betrag der Beschleunigung ohne Schwerkraft (oben) und der Winkelgeschwindigkeit (unten) während des Abschreibens, einer Pause und des Tippens auf einer Tastatur. Grün hinterlegt sind die Abschnitte, in denen der Stift laut Ground Truth Kontakt mit dem Papier hatte.

Das Tipp-Problem ist stark personenabhängig. Bei P31 werden 68 % der Tastatur- und 63 % der Handy-Fenster als Schreiben gelesen, bei P63 80 % der Handy-Fenster, bei P34 66 %; bei P26, P27, P57 und P71 liegen beide Raten unter 5 %. Die drei Personen mit der niedrigsten Gesamtgenauigkeit (P73, P31, P63) gehören alle zur ersten Gruppe. Bei 20 Personen lagen die gepoolten Raten mit 0,36 und 0,25 noch deutlich höher; die zwölf zusätzlichen Personen mit Tipp-Aufgaben haben sie auf 0,22 und 0,17 gedrückt, ohne dass sich das im Gesamtmittel niederschlägt, weil zugleich neue schwierige Personen hinzukamen.

Für eine dieser Personen (P17) haben wir den Mechanismus nachvollzogen. Ihr Tippen erzeugt am Handgelenk Gyroskop-Ausschläge derselben Größenordnung wie ihr Schreiben (Effektivwert 1,64 gegenüber 1,25 rad/s), während eine Kontrollperson beim Tippen bei 0,31 rad/s liegt. Eine SHAP-Analyse (Lundberg & Lee, 2017) der korrekt erkannten Schreibfenster und der falsch als Schreiben gelesenen Tipp-Fenster ergibt eine Korrelation

der Merkmalsbeiträge von $r = 0,63$: Die Mehrheit der Merkmale sieht in beiden dasselbe. Zwei Merkmale trennen (Anteil des 3-bis-8-Hz-Bands der Rotationsachse x und der Jerk des Gyroskop-Betrags), werden aber überstimmt. Das erklärt, warum die in Abschnitt 6.3 beschriebenen Merkmalseingriffe wirkungslos blieben: Die Information ist vorhanden, aber für eine Person mit diesem Tippstil in der Trainingsmenge unterrepräsentiert.

Die schwachen Personen zerfallen in zwei Klassen, die sich am HMM-Gewinn ablesen lassen. P73 gewinnt durch den Filter 6,7 Prozentpunkte, seine Fehler sind also hochfrequentes Flackern, das Zeitkontext beseitigt. P31 gewinnt nur 2,7 Punkte und P17 nur 1,2: Ihre Fehler sind stabil falsche Emissionen über ganze Aufgabenblöcke, und ein Übergangsmodell kann eine falsche, aber konsistente Emission nicht korrigieren.

7 Diskussion

Die Forschungsfrage lautete, ob sich Schreibaktivität allein aus den IMU-Daten einer Smartwatch erkennen lässt, unabhängig von der Person, die sie trägt. Die Antwort ist ja, mit einer klar benennbaren Grenze. Auf 32 Personen, von denen jede für ihr eigenes Testergebnis nie im Training war, erreicht ein zeitliches Faltungsnetz auf 5-s-Fenstern 92 % Genauigkeit, und ein Random Forest auf handgebauten Merkmalen mit kausalem HMM-Filter 90 %. Beide Zahlen sind ohne Kenntnis der Person, ohne Kalibrierungsphase und ohne Blick in die Zukunft erreichbar. Was fehlt, sind die restlichen acht bis zehn Prozent, und die Ergebnisse sagen ziemlich genau, wo sie sitzen.

Die Grenze des Merkmalsmodells liegt vermutlich in der Repräsentation. Über den größten Teil des Projekts sah es so aus, als läge die Leistungsgrenze im Signal. Random Forest, MiniRocket, ein vortrainiertes Modell und die Netze auf 1-s-Fenstern trafen dieselbe Marke und scheiterten an denselben Personen; kein Merkmalseingriff, keine Augmentation, keine Ungewichtung bewegte sie. Der Schritt von 22 auf 32 Personen trennt diese Lesart, wenn auch nicht sauber: Der Random Forest blieb stehen, die Netze stiegen — zugleich änderten sich Kohortenzusammensetzung und Protokollanteil, sodass die Beobachtung nicht allein der Personenzahl zuzuschreiben ist. Die naheliegende Deutung ist, dass nicht das Signal erschöpft ist, sondern das, was Statistiken über ein 1-s-Fenster ausdrücken können. Ein Netz, das die Reihenfolge der Bewegungen innerhalb von fünf Sekunden sieht, profitiert anders als der Random Forest weiter von zusätzlichen Personen. Dass die Netze im Modern-Pool auf 23 Personen den Schwerkraftvektor nutzen können, während der Random Forest auf vier Personen daran scheiterte, passt in dasselbe Bild.

Zeitkontext ist der entscheidende Hebel, und man kann ihn nur einmal einsammeln. Drei ganz verschiedene Wege führen auf dieselbe Höhe: ein Netz auf nativen 5-s-Fenstern, ein 1-s-Modell mit HMM, und die Fusion von Random Forest und Netz. Das HMM hilft nur Modellen ohne eigenes Gedächtnis; sobald das Basismodell fünf Sekunden Kontext trägt, überglättet es. Dass der Rolling-Mean auf keiner Skala hilft, das HMM aber auf jeder, zeigt,

dass es nicht um Mittelung geht, sondern um ein Modell der Übergänge: Schreiben ist ein Zustand mit Trägheit, und ein Detektor, der das weiß, darf bei schwacher Evidenz beim letzten Zustand bleiben. Für den Einsatz ist damit die Frage nach der Latenz entscheidend. Wer eine Anzeige im Moment will, bekommt 0,90; wer abends den Tag rekonstruiert, bekommt 0,92, weil der Smoother beide Seiten eines Übergangs sehen darf. Diese Differenz von knapp zwei Prozentpunkten ist in 31 von 32 Personen dieselbe und war bei 22 Personen schon vorhanden; sie gehört zu den robustesten Befunden der Arbeit.

Der Restfehler ist personen- und aufgabenspezifisch, nicht diffus. Die Fehler des Modells liegen nicht gleichmäßig über allen Nicht-Schreib-Situationen, sondern konzentrieren sich auf zwei Muster: Tippen auf Tastatur oder Handy bei einem Teil der Personen und sehr leises oder stark unterbrochenes Schreiben bei einem anderen Teil. Beide Muster sind am Handgelenk physikalisch begründet. Wer beim Tippen die Hand ähnlich bewegt wie beim Schreiben, erzeugt ähnliche Rotationen; wer sehr leicht schreibt, erzeugt kaum mehr Bewegung als in Ruhe. Für das Tippen konnten wir zeigen, dass die trennende Information in den Merkmalen vorhanden ist, aber von der Mehrheit der Merkmale überstimmt wird, und dass alle Versuche, sie per Merkmalsdesign oder Gewichtung durchzusetzen, gescheitert sind. Der gepoolte Tipp-Fehler ist mit den zusätzlichen Personen von 36 auf 22 Prozent gefallen, ohne dass jemand daran gearbeitet hätte. Mehr Personen mit verschiedenen Tippstilen sind offenbar der Hebel, den Merkmalsdesign nicht ersetzen kann.

Was die Zahlen messen, entscheidet die Labeldefinition. Das Schließen von Lücken bis 2,5 s macht aus der Frage *berührt der Stift das Papier* die Frage *ist die Person im Schreibmodus*. Für einen Schreibzeit-Tracker ist das die richtige Frage, und sie ist für das Modell lernbar, weil das Handgelenk in Mikropausen dasselbe tut wie in den Strichen. Die Kehrseite ist sichtbar: Rechenaufgaben mit Denkpausen über 2,5 s bleiben schwierig, weil die Semantik dort ausfranst, und ein Schätzer für den Schreibanteil überschätzt die rohe Stiftzeit systematisch um rund 20 Prozentpunkte. Beides ist kein Modellfehler, sondern eine Folge der Definition, und beides muss bei jeder Anwendung mitgedacht werden.

Wo die Ergebnisse tragen und wo sie Hypothesen bleiben. Belegt sind, jeweils gepaart über Personen und mit $p < 0,05$: der Gewinn des HMM-Filters, der Vorsprung des Smoothers, der Vorsprung der nativen 5-s-Netze gegenüber dem Random Forest bei 15 und 20 Personen, der Gewinn der Fusion, die Kosten des fehlenden Gyroskops und die Wirkung der Korrekturen an der Zeitachse. Nominal, aber nicht belegt sind die Rangfolge der beiden Netze, der Vorsprung der Netze bei 32 Personen (der Abstand ist groß, die personenweisen Vorhersagen liegen aber nicht vor) und die Wirkung des Schwerkraftvektors auf tcn6. Hypothesen sind die Erklärungen: dass der rekurrente Kopf Lageinformation aus dem Verlauf rekonstruiert, und dass die Tipp-Verwechslung mit mehr Personen weiter schrumpft. Wir haben im Verlauf des Projekts zweimal einen scheinbar sauberen Befund zurücknehmen müssen, einmal wegen eines Sortierfehlers, einmal wegen eines verschobenen Zeitver-

satzes. Beide Male war nicht die Statistik falsch, sondern die Daten darunter. Das ist der Grund, warum diese Arbeit so viel Platz auf Zeitachsen und Kontrollen verwendet.

8 Limitationen

Kohorte. 32 Personen sind für eine personenunabhängige Aussage eine tragfähige Grundlage, aber die Kohorte ist homogen: überwiegend Studierende, ein Aufnahmerraum, ein Tisch, ein Uhrenmodell, die Uhr immer am Schreibhandgelenk. Händigkeit, Alter und Schreibgewohnheit wurden nicht erfasst. Die Ergebnisse sagen nichts über Kinder, ältere Menschen, Linkshänder mit der Uhr an der rechten Hand oder Personen mit motorischen Einschränkungen. Die Streuung zwischen Personen von 3,5 Prozentpunkten ist in jeder unserer Kennzahlen die dominante Unsicherheit.

Kontrollierte Aufgaben. Alle Daten stammen aus einem Protokoll mit vorgegebenen Aufgaben von ein bis vier Minuten. Das ist die Voraussetzung für die Ground Truth und für die Auswertung je Aufgabe, aber es ist nicht der Alltag. Im Alltag sind Schreibphasen seltener, kürzer und weniger klar begrenzt, und die Negativklasse ist unvergleichlich breiter als unsere sechs Nicht-Schreibaufgaben. Ein Schreibanteil von 43 % wie im Datensatz ist eine Folge des Protokolls und im Alltag kaum zu erwarten; belegen können wir das mit unseren Daten nicht, weil sie ausschließlich unter dem Protokoll entstanden sind. Bei stark schiefen Anteilen schrumpft ein Schätzer des Schreibanteils zur Mitte, was wir auf den Sitzungsblöcken gemessen haben. Eine Aufzeichnung über ganze Tage mit einer anderen Form der Ground Truth (Tagebuch, Video) steht aus.

Zwei Datenpools. Die Umstellung auf 100 Hz mit Schwerkraftvektor mitten in der Erhebung zwingt zu zwei Pools. Alle Hauptergebnisse laufen auf dem Legacy-Pool, in dem 23 der 32 Aufnahmen heruntergerechnet sind. Der Dezimierer ist phasenneutral und anti-aliasing-gefiltert, und ein explorativer Vergleich 50 gegen 100 Hz auf zwei Aufnahmen einer einzigen Person ergab keinen Unterschied; trotzdem ist der Legacy-Pool eine Mischung aus nativen und abgeleiteten Signalen. Die Aussagen zum Schwerkraftvektor stützen sich auf die 23 Personen des Modern-Pools und sind nicht mit den 32-Personen-Zahlen vergleichbar.

Ground Truth aus dem Stift. Die Labels sind so gut wie die zeitliche Ausrichtung und die Labeldefinition. Die Ausrichtung ist auf 10 ms aufgelöst und über die Aufnahme stabil; das Toleranzfenster von ± 40 ms und das Schließen von Lücken bis 2,5 s sind aber Festlegungen, und beide erzeugen Fenster, die inhärent mehrdeutig sind (Übergänge, lange Denkpausen). Zwei Aufnahmen trugen über Wochen einen falschen Zeitversatz, bevor eine Plausibilitätsgrenze ihn aufdeckte; eine davon war Gegenstand einer ausführlichen Fehlanalyse. Wir haben die Konsequenz der Alignment-Annahme (Schreiben ist die dynamischere Klasse) und den Zusammenhang zwischen Alignment-Diagnostik und Genauigkeit

geprüft, aber es gibt keine videobasierte Kontrolle der Labels. Eine manuelle Annotation einiger Aufnahmen gegen Video wäre der Goldstandard, den wir nicht geleistet haben.

Statistische Absicherung der Netze. Die Netze wurden mit drei Saaten auf fünf Gruppen trainiert, aber die Läufe auf 32 Personen haben keine personenweisen Vorhersagen gespeichert. Damit sind bei 32 Personen weder die Rangfolge der beiden Netze noch ihr Abstand zum Random Forest gepaart getestet; der Abstand zum Random Forest ist mit fünf bis sechs Prozentpunkten zwar um eine Größenordnung größer als jede beobachtete Streuung, ein formaler Test fehlt aber. Die Nichtdeterminiertheit der GPU-Kerne (bis 1,6 Prozentpunkte bei identischer Saat) begrenzt außerdem, wie fein Architekturen überhaupt unterscheidbar sind. Hinzu kommt, dass Architektur- und Hyperparameterwahl auf derselben Kohorte stattfanden, auf der wir berichten (Abschnitt 5.1): Die Werte der Netze sind Selektionssieger und damit systematisch nach oben verzerrt.

Binäre Zielgröße. Das Modell unterscheidet Schreiben von allem anderen. Es unterscheidet nicht zwischen Schreiben und Zeichnen, nicht zwischen Handschrift und Skizze, und es sagt nichts darüber, was geschrieben wird oder ob die Person dabei aufmerksam ist. Der Schreibanteil je Aufgabe, den wir als Engagement-Proxy ausgewertet haben, ist genau das: ein Proxy. Eine Person kann konzentriert nachdenken, ohne zu schreiben.

Einsatz auf dem Gerät. Der Random Forest mit HMM-Filter läuft im Live-Dashboard, und die Ablation ohne Gyroskop zeigt, dass ein passiver Ganztags-Tracker auf der Watch mit etwa einem Prozentpunkt Verlust möglich ist. Die Messung, ob die Hintergrund-Sensorik der Watch über zwölf Stunden tatsächlich 50 Hz liefert und ob das konvertierte Modell auf der Uhr die gleichen Vorhersagen erzeugt wie auf dem Rechner, steht zum Zeitpunkt dieses Berichts noch aus.

9 Fazit und Ausblick

Schreibaktivität lässt sich aus den IMU-Daten einer Apple Watch am Schreibhandgelenk personenunabhängig erkennen. Mit 32 Personen, einem instrumentierten Stift als Ground Truth und einer Evaluation, bei der keine Person je in ihrem eigenen Training war, erreicht ein zeitliches Faltungsnetz mit rekurrentem Kopf auf 5-s-Fenstern 0,921 Genauigkeit und 0,975 ROC-AUC, gemittelt über drei Zufallssaaten und ohne gepaarten Test gegen die übrigen Modelle. Ein Random Forest auf 88 handgebauten Merkmalen erreicht je Sekunde 0,865 und mit einem kausalen Zwei-Zustands-HMM 0,898; rückblickend dekodiert 0,917. Die Wahrscheinlichkeiten sind kalibriert, das HMM ist ohne Neutraining einsetzbar und läuft im Live-System.

Drei Erkenntnisse gehen über die Zahlen hinaus. Erstens deuten die Ergebnisse darauf hin, dass die Grenze des Merkmalsmodells eher in der Repräsentation als im Signal liegt: Zwölf zusätzliche Personen haben den Random Forest nicht bewegt, die Netze aber schon

— bei allerdings zugleich veränderter Zusammensetzung der Kohorte. Zweitens ist Zeitkontext der wirksamste Hebel und lässt sich nur einmal einsammeln, in der Repräsentation oder nachträglich, mit einem Aufschlag von zwei Prozentpunkten für alles, was nicht live entschieden werden muss. Drittens sind die verbleibenden Fehler nicht diffus, sondern sitzen bei bestimmten Personen in bestimmten Aufgaben, vor allem beim Tippen, und dort ist die Trainingsvielfalt der Hebel, nicht das Merkmalsdesign.

Der nächste Schritt liegt deshalb weniger im Modell als in den Daten: den Datensatz um Personen zu erweitern, die anders tippen und anders schreiben als die bisherige Kohorte, und einen Teil der Aufnahmen gegen Video zu annotieren, damit die Labeldefinition selbst überprüfbar wird. Beides ist Erhebungsarbeit, und die Ergebnisse dieser Arbeit legen nahe, dass sie mehr bewirkt als weitere Rechenzeit.

Literatur

- Apple Inc. (2026a). *Core motion: Process accelerometer, gyroscope, pedometer, and environment-related events*. <https://developer.apple.com/documentation/coremotion>. (Abgerufen am 2. September 2026)
- Apple Inc. (2026b). *Watch connectivity: Implement two-way communication between an iOS app and its companion watchOS app*. <https://developer.apple.com/documentation/watchconnectivity>. (Abgerufen am 2. September 2026)
- Bai, S., Kolter, J. Z., & Koltun, V. (2018). *An empirical evaluation of generic convolutional and recurrent networks for sequence modeling*. arXiv:1803.01271 [cs.LG]. (Preprint, nicht begutachtet) doi: 10.48550/arXiv.1803.01271
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi: 10.1023/A:1010933404324
- Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). *Empirical evaluation of gated recurrent neural networks on sequence modeling*. arXiv:1412.3555 [cs.NE]. (Preprint, nicht begutachtet) doi: 10.48550/arXiv.1412.3555
- Dempster, A., Schmidt, D. F., & Webb, G. I. (2021). MiniRocket: A very fast (almost) deterministic transform for time series classification. In *Proceedings of the 27th acm sigkdd conference on knowledge discovery and data mining* (pp. 248–257). doi: 10.1145/3447548.3467231
- Ismail Fawaz, H., Lucas, B., Forestier, G., Pelletier, C., Schmidt, D. F., Weber, J., ... Petitjean, F. (2020). InceptionTime: Finding AlexNet for time series classification. *Data Mining and Knowledge Discovery*, 34(6), 1936–1962. doi: 10.1007/s10618-020-00710-y
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in neural information processing systems* (Vol. 30, pp. 4765–4774).
- Neo smartpen. (2023). *WEB-SDK2.0: Neo smartpen SDK 2.0 for web platform*. <https://github.com/NeoSmartpen/WEB-SDK2.0>. (Abgerufen am 2. September 2026; TODO: verwendeten Commit-Hash eintragen)

- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. In *Advances in neural information processing systems* (Vol. 32, pp. 8024–8035).
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Rabiner, L. R. (1989). A tutorial on hidden Markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2), 257–286. doi: 10.1109/5.18626
- Sensor Logger. (2026). *Sensor logger: Mobile sensor data logging application*. <https://www.tszheichoi.com/sensorlogger>. (Abgerufen am 2. September 2026)
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83.
- Williams, E. J. (1949). Experimental designs balanced for the estimation of residual effects of treatments. *Australian Journal of Scientific Research, Series A*, 2(2), 149–168.
- Yuan, H., Chan, S., Creagh, A. P., Tong, C., Acquah, A., Clifton, D. A., & Doherty, A. (2024). Self-supervised learning for human activity recognition using 700,000 person-days of wearable data. *npj Digital Medicine*, 7, 91.